

基于TGV和灰度通道相似性的深度补全

lwj

2021 年 11 月 13 日

目录

1	利用优化实现颜色修复	3
1.1	局部颜色相似性假设	3
1.2	基于局部颜色相似性的颜色修复模型	3
1.3	模型改进	4
2	基于tgv的深度数据恢复	6
2.1	ITGV	6
2.2	STGV	7
2.3	TGV收敛问题	8
3	TGV和colorize结合	10
3.1	利用COLORIZE作为保真项	10
3.2	利用COLORIZE优化后的结果作为初始值进行STGV优化 . .	12
3.3	接下来的工作	12

1 利用优化实现颜色修复

1.1 局部颜色相似性假设

深度恢复和颜色恢复从某种程度上是一样的，Levin^[1]假设在邻域内，图像颜色存在线性相关性，他利用这种相关性对彩色图像进行了颜色恢复(colorization)的工作，Levin^[1]提到相似性的两种度量方式如下：

$$w(i, j) \propto 1 + \frac{1}{\sigma_j^2} (I(i) - \mu_i)(I(j) - \mu_i) \quad (1)$$

$$w(i, j) \propto \exp \frac{-(I(i) - I(j))^2}{2\sigma_i^2} \quad (2)$$

式(1) 和 (2)中 $w(i, j)$ 表示在 j 和 i 处颜色的线性因子，一个朴素的假设是不同通道局部相似性因子 $w(i, j)$ 是相近的，因此在已知其中一个通道数据的情况下，其他通道的 w ，可以通过已知通道（例如灰度 I ）近似求解。

1.2 基于局部颜色相似性的颜色修复模型

对于 m 行 n 列的图像，假设已知某一通道的数据 I ，待恢复的颜色通道的数据为 f ，其中未知颜色数据的区域为 Z ，所有图像区域为 $\Omega = [1, mn)$ ， $u, f \in R^{mn}$ ， $f(i) = 0, i \in Z$ ，通过求解损失函数(3)最小值得问题，即可恢复缺失的颜色数据

$$J(u) = \sum_{i \in Z} \left\| u(i) - \sum_{j \in N(i, r), j \neq i} w(i, j) u(j) \right\|^2 \quad (3)$$

(3)可以写成矩阵的形式：

$$\begin{aligned} J(u) &= \|(I - W)u - f\|^2 \\ &= \sum_{i \in Z} \left(u(i) - \sum_{j \in N(i, r)} w(i, j) u(j) \right)^2 + \sum_{i \in \Omega \setminus Z} (u(i) - f(i))^2 \end{aligned} \quad (4)$$

其中稀疏矩阵 $W \in R^{mn \times mn}$ 如下

$$W(i, j) = \begin{cases} \frac{w(i, j)}{\sum_{j \in N(i, r), j \neq i} w(i, j)} & , j \in N(i, r), j \neq i, i \in Z \\ 0 & , others \end{cases} \quad (5)$$

最小化(4)可以通过最小二乘法进行求解

$$u = ((I - W)^T(I - M))^{-1}(I - W)^T f \quad (6)$$

(6)可以通过 $eigen$ 求解，但是实际发现求解稀疏矩阵线性问题的效率上， $matlab$ 会更高一些。

1.3 模型改进

此外flyfj^[2]对(4)的一种改进为

$$J(u) = \underbrace{\|(\alpha_c G + I - W')u - \alpha_c f\|^2}_{\text{约束项}}, \alpha_c \in [0, 1] \quad (7)$$

$$= \sum_{i \in \Omega} \left(u(i) - \sum_{j \in N(i, r)} w(i, j)u(j) \right)^2 + \underbrace{\alpha_c \sum_{i \in \Omega \setminus Z} (u(i) - f(i))^2}_{\text{保真项}} \quad (7)$$

$$W'(i, j) = \begin{cases} \frac{w(i, j)}{\sum_{j \in N(i, r), j \neq i} w(i, j)} & , j \in N(i, j), j \neq i, i \in \Omega \\ 0 & , others \end{cases} \quad (8)$$

$$G(i, j) = \begin{cases} 1, i = j \text{ and } f(i) \neq 0 \\ 0, others. \end{cases} \quad (9)$$

相似性约束的范围也从未知图像区域 Z 扩展到整个图像区域 Ω ，改进之后的模型能够更好的约束修复数据，不仅包含已知 $\Omega \setminus Z$ 对 Z 的约束，同时 Z 对其他区域 $\Omega \setminus Z$ 也被考虑进去了。引入了惩罚因子 α_c ，表征保真项的权值。改进之后，其深度恢复效果得到很大的提升。图1是仅使用未知区域约束项的效果，图2是使用全局约束项的效果，对应的惩罚因子 $\alpha_c = 1.0$ 。可以看出深度修复的效果得到明显提升，一个原因是用来恢复深度信息的数据更多了。

另一种改进是针对线性系数 $w(i, j)$ 的一种改进。Levin^[1]的模型在图像边缘处的效果比较差，特别是未知区域 Z 和已知区域 $Y = \Omega \setminus Z$ 的边缘正好和 rgb 图像边缘正好重叠的区域(见图3),由于该区域其他方向的深度信息不



图 1: 只使用未知区域局部约束



图 2: 使用了全局约束项

可用，而已知区域的深度信息对该区域又通过一个比较小的权值 $w(i, j)$ 进行影
响。这种区域在进行深度数据坐标系变换之后是非常常见的区域。
因此可以对图像进行语义分割，划分成不同的区块，对属于不同区块的权




图 3: 优化效果比较差的区域,图中红框

值 $w(i, j)$ 直接置零。

$$W''(i, j) = \begin{cases} \frac{w(i, j)}{\sum_{j \in N(i, r), j \neq i} w(i, j)} & , j \neq i, seg(i) = seg(j), j \in N(i, j), i \in \Omega \\ 0 & , others \end{cases} \quad (10)$$

其中 $seg(i)$ 返回 i 处的所属的语义分割集合的 id 。如图由于减少了不同区域的
错误影响，其优化效果得到一定的提升。

由于将属于不同区域的权值置零了。矩阵 W' 的稀疏程度增加，容易产
生奇异性。需要进一步考虑算法处理。



图 4: 使用全局约束但是没有利用语义分割

图 5: 利用语义分割优化全局约束

2 基于tgv的深度数据恢复

2.1 ITGV

Ranftl^[3] 提出使用Nagel-Enkelmann算子^[4]将结构信息融入到TGV模型中的正则化手段ITGV。其公式如(11)

$$ITGV_{\alpha}^2(u) = \min_{w \in \mathbb{R}^2} \left\{ \alpha_u \int_{\Omega} \left| D^{\frac{1}{2}} \nabla u - w \right| dx + \alpha_w \int_{\Omega} |\nabla w| dx \right\} \quad (11)$$

其中的 $D^{\frac{1}{2}}$ 为Nagel-Enkelmann算子

$$D^{\frac{1}{2}} = \exp \left(-\gamma |\nabla I_L|^{\beta} \right) nn^T + n^{\perp} n^{\perp T} \quad (12)$$

n 是图像梯度的方向, $n = \frac{\nabla I_L}{|\nabla I_L|}$, n^{\perp} 垂直于 n , γ 和 β 是自定义参数。Ferstl^[5]进一步的提出, 用ITGV进行深度数据上采样的方法, 并取得了较好的效果。其模型见下式(13)

$$J(u, w) = ITGV_{\alpha}^2(u, w) + \int_{\Omega} \lambda |u - f|^2 dx \quad (13)$$

其中系数 λ 在深度数据缺失的区域为零。即 $\lambda(i) = 0, i \in Z$ 。TGV正则化, 能够在保留边缘的同时, 去除噪声, 在已有深度数据的区域 $D = \Omega \setminus Z$ 由于其具有各项异性的传播特性, 能够衰减梯度方向的传播, 保留梯度切线方向的传播, 因此能够比较好的保留原始图像的边缘信息, 但是在深度为零的区域, 这种正则化作用由于没有原始数据的边缘梯度做为参考, 这种正则化作用就被减弱了。因此通过引入结构化参数 $D^{\frac{1}{2}}$ 将灰度通道的数据的边缘信息作为参照, 保证了ITGV在深度缺失区域的各项异性。

2.2 STGV

Drozhdov进一步的提出改进的边缘算子^[6]用于深度恢复。并在已有的数据集上取得了不错的效果。STGV基于超像素技术，将rgb图像进行超像素处理，计算每个超像素内的深度分布，提出异常点，利用DBSCAN聚类算法实现超像素的合并。同时利用贪婪算法，保证每个超像素块内的已知深度区域具有足够的比例。利用超像素信息，进一步加强边缘算子的各向异性，见式(14)。

$$\mathbb{D} = \Gamma n n^T + n^\perp n^{\perp T} \quad (14)$$

其中 Γ 为边缘指示函数，见式(15)，

$$\Gamma = \begin{cases} 1 & \text{inside segment,} \\ 0 & \text{segment border} \end{cases} \quad (15)$$

将式(14)代入式(13)中得到

$$J(u) = \min_{w \in \mathbb{R}^2} \left\{ \alpha_u \int_{\Omega} |(D)\nabla u - w| dx + \alpha_w \int_{\Omega} |\nabla w| dx \right\} + \int_{\Omega \setminus Z} \lambda |u - f|^2 dx \quad (16)$$

超像素边缘在一定程度上是贴合物体的轮廓，在超像素边缘(一定程度上也是图像边缘)区域，通过(15)完全抑制了法线方向的扩散，深度修复具有各向异性。而在超像素内部，具有各向同性传播。因此STGV能够取得由于ITGV的效果。见图6和7，迭代了14730次（耗时1009秒），参数为： $\alpha_w = 5, \alpha_u = 1.2, \lambda = 50, \gamma = 0.85, \beta = 9$ 。



图 6: ITGV深度修复效果



图 7: STGV效果(图像边缘经过手动调整)

STGV存在一下几个问题：

- 1) 效果严重依赖超像素算法对边缘识别的准确度，如果边缘识别错误，则深度修复会带来很严重的错误，修复效果还不如ITGV正则化的效果，见图8和图9
- 2) 优化算法需要迭代很久才能够收敛。对于 648×486 分辨率的数据，在I7 GTX2080配置的电脑上跑了数个小时都优化不出来。




图 8: 错误的超像素结果



图 9: 错误超像素产生的深度修复效果

注意，为了增加图像对比度，图6,7,9做了最大值归一化处理。后续深度图如无特殊说明，均做了同样的处理

2.3 TGV收敛问题

TGV问题一般使用交替方向乘子法 (Alternating Direction Method of Multipliers, ADMM) 求解。Chambolle^[7]提出了基于prime-dual的算法实现,见算法1，收敛速度优于交替方向乘子法。对于求解鞍点问题(17)

$$\min_{x \in X} \max_{y \in Y} \langle Kx, y \rangle + G(x) - F^*(y) \quad (17)$$

其中 $\langle \cdot, \cdot \rangle$ 表示对偶积，离散情况下可以看成是向量的点乘。可以使用算法1进行求解。其中 $L = \|K\|$ 表示算子 K 的范数。

针对 K 比较复杂的情况，其范数往往比较难计算，可以根据Pock^[8]提到的做法，用算法2求解 算法2可以看成是Chambolle^[7]提到的Algorithm2和Pock^[8]提到的算法的结合版本。

Algorithm 1 pdAlg1

Initialization: Choose $\tau, \sigma > 0, \theta \in [0, 1], (x^0, y^0) \in X \times Y$ and set $\bar{x}^0 = x^0$. s.t. $\tau\sigma L^2 < 1$

Iterations($n \geq 0$): Update x^n, y^n, \bar{x}^n as follows :

$$\begin{cases} y^{n+1} = (I + \sigma \partial F^*)^{-1}(y^n + \sigma K \bar{x}^n) \\ x^{n+1} = (I + \tau \partial G)^{-1}(x^n - \tau K^* y^{n+1}) \\ \bar{x}^{n+1} = x^{n+1} + \theta(x^{n+1} - x^n) \end{cases} \quad (18)$$

Algorithm 2 pdPrecondition

Initialization: Choose $\tau_0, \sigma_0 > 0$ with $\tau_0 \sigma_0 L^2 \leq 1, (x^0, y^0) \in X \times Y$ and set $\bar{x}^0 = x^0$.

Caculate Tensors: Choose $\alpha \in [0, 2]$ and Caculate as follow :

$$\begin{aligned} T &= \text{diag}(\boldsymbol{\tau}), \text{ where } \boldsymbol{\tau} = (\tau_1, \dots, \tau_n), \tau_j = \frac{1}{\sum_{i=1}^m |K_{i,j}|^{2-\alpha}}, \\ \Sigma &= \text{diag}(\boldsymbol{\sigma}), \text{ where } \boldsymbol{\sigma} = (\sigma_1, \dots, \sigma_m), \sigma_i = \frac{1}{\sum_{j=1}^n |K_{i,j}|^\alpha} \end{aligned} \quad (19)$$

Iterations($k \geq 0$): Update x^n, y^n, \bar{x}^n as follows :

$$\begin{aligned} x^{k+1} &= (I + \tau_k T \partial G)^{-1}(x^k - \tau_k T K^T y^k), \\ y^{k+1} &= (I + \sigma_k \Sigma \partial F^*)^{-1}(y^k + \sigma_k \Sigma K \bar{x}^k). \\ \theta_k &= \frac{1}{\sqrt{1 + 2\gamma\tau_k}}, \tau_{k+1} = \theta_k \tau_k, \sigma_{k+1} = \frac{\sigma_k}{\tau_n} \\ \bar{x}^{k+1} &= x^{k+1} + \theta_k(x^{k+1} - x^k) \end{aligned} \quad (20)$$

3 TGV和colorize结合

可以考虑将TGV和colorize结合，优化图像效果。具体做了两种尝试：

3.1 利用COLORIZE作为保真项

一种思路是将(7)(8)作为保真项，采用TGV作为正则化，进行问题的求解，如式(21)。下面简称为CSTGV(colorized superpixel total generalize variation)。

$$J(u, w) = \alpha_u \sum |\mathbb{D}(\nabla u - w)| + \alpha_w \sum |\xi w| + \sum \frac{1}{2\lambda} \|Au - \alpha_c f\|^2 \quad (21)$$

其中 $A = \alpha_c G + I - W'$ ，通过灰度数据可以计算出来。 Au 可以通过matlab实现。采用改进的prime-dual算法来实现优化,原始的问题(21)的Fenchel - Legendre对偶形式为：

$$\begin{aligned} \min_{(u,w) \in U \times V} \max_{(p,q,r) \in V \times W \times U} & \overbrace{\langle \mathbb{D}(\nabla u - w), p \rangle + \langle \xi w, q \rangle + \langle W'u, r \rangle}^{\langle Kx, y \rangle} \\ & - \underbrace{\left[\langle \alpha_c f, r \rangle + \frac{\lambda}{2} \|r\|^2 + \mathbb{I}_{\{\|\cdot\|_\infty \leq \alpha_u\}}(p) + \mathbb{I}_{\{\|\cdot\|_\infty \leq \alpha_w\}}(q) \right]}_{F^*(y)} \end{aligned} \quad (22)$$

对应于式(17)式(22)中的 $G(x) = 0, K$ 如下

$$K = \begin{bmatrix} \mathbb{D}\nabla & -\mathbb{D} \\ 0 & \xi \\ A & 0 \end{bmatrix} \quad (23)$$

其中的差分算子 ∇ 使用前向差分算子,对 m 行 n 列的图像

$$\begin{aligned} \nabla &= \begin{bmatrix} \nabla_x \\ \nabla_y \end{bmatrix} \\ \nabla_x &= I_m \otimes \nabla_f \\ \nabla_y &= \nabla_f \otimes I_m \end{aligned} \quad (24)$$

其中 \otimes 表示Kronecker内积。 I_m 是 $m \times m$ 维的单位矩阵， ∇_f 表示带有循环边界的一维差分算子， $\nabla_f \in R^{n \times n}$ 。

$$\nabla_f = \begin{bmatrix} -1 & 1 & 0 & 0 \\ 0 & \ddots & \ddots & 0 \\ 0 & 0 & -1 & 1 \\ 1 & 0 & 0 & -1 \end{bmatrix} \quad (25)$$

图10和 图11分别是STGV和CSTGV的优化效果。用到的参数为：



图 10: STGV原始效果



图 11: colorize保真项CSTGV优化效果

$itertimes = 54740, \alpha_w = 5, \alpha_u = 1.2\lambda = 1e - 2$ (式(21)的 λ 和(13)的 λ 不同)。对于图像恢复，调节保真项权值 λ 能够提升效果。如图13和12，在 $itertimes = 54740, \alpha_w = 5, \alpha_u = 1.2, \lambda = 1e - 4$ 参数下，效果明显优于图10和图11



图 12: STGV $\lambda = 1e - 4$,耗时4051.26s



图 13: CSTGV $\lambda = 1e - 4$,耗时5253s

3.2 利用COLORIZE优化后的结果作为初始值进行STGV优化

STGV收敛速度慢的一个解决手段，可以通过选取合适的初始值来解决。而colorize得到的结果存在比较多的毛刺，可以简单的将两个算法流程串联。以提升效果。需要注意的是，colorize得到的结果(记为 g)和原始输入 f 需要经过相同的归一化因子归一化，否则会导致尺度上的错误。效果见图14



图 14: 对colorize优化后的图像进行tgv平滑操作

使用参数为 $\alpha_u = 1.2, \alpha_w = 4.5, \lambda = 40, itertimes = 2000$

3.3 接下来的工作

研究其他的深度修复算法，同时考虑完善现有算法的一些细节，

- 使用分割信息之后colorize的奇异问题;
- tgv收敛和算法2中参数 γ 的关系

- c++实现和matlab实现的colorize算法存在局部数据差异
- matlab实现cstgv, 并测试效果
- 完善原先代码前向循环边界差分部分

参考文献

- [1] Anat Levin, Dani Lischinski, and Yair Weiss. Colorization using optimization. *ACM Trans. Graph.*, 23(3):689–694, August 2004.
- [2] flyfj. Visiontoolbox. https://github.com/flyfj/VisionToolbox/blob/master/3D/DepthEnhancer/colorization/fill_depth_colorization.m/ Accessed November 12, 2021.
- [3] René Ranftl, Stefan Gehrig, Thomas Pock, and Horst Bischof. Pushing the limits of stereo using variational stereo estimation. In *2012 IEEE Intelligent Vehicles Symposium*, pages 401–407, 2012.
- [4] Hans-Hellmut Nagel and Wilfried Enkelmann. An investigation of smoothness constraints for the estimation of displacement vector fields from image sequences. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8(5):565–593, 1986.
- [5] David Ferstl, Christian Reinbacher, Rene Ranftl, Matthias Ruether, and Horst Bischof. Image guided depth upsampling using anisotropic total generalized variation. In *2013 IEEE International Conference on Computer Vision*, pages 993–1000, 2013.
- [6] Gilad Drozdov, Yevgeny Shapiro, and Guy Gilboa. Robust recovery of heavily degraded depth measurements. In *2016 Fourth International Conference on 3D Vision (3DV)*, pages 56–65, 2016.
- [7] Antonin Chambolle and Thomas Pock. A first-order primal-dual algorithm for convex problems with applications to imaging. *Journal of Mathematical Imaging and Vision*, 40(1):120–145, May 2011.

- [8] Thomas Pock and Antonin Chambolle. Diagonal preconditioning for first order primal-dual algorithms in convex optimization. In *2011 International Conference on Computer Vision*, pages 1762–1769, 2011.