

工作日志

lwj

2021 年 11 月 25 日

目录	2
----	---

目录

1	tg_v和深度补全的收尾工作	3
1.1	colorize相关矩阵奇异的处理	3
1.2	tg _v 收敛问题	3
2	单目深度测算	7
2.1	色差dfd	7
3	接下来的工作	9

1 tgv和深度补全的收尾工作

1.1 colorize相关矩阵奇异的处理

$$W''(i, j) = \begin{cases} \frac{w(i, j)}{\sum_{j \in N(i, 2r), j \neq i} w(i, j)} & , j \neq i, \text{seg}(i) = \text{seg}(j), j \in N(i, r), i \in \Omega \\ 0 & , \text{others} \end{cases} \quad (1)$$

其中 $\text{seg}(i)$ 返回 i 处的所属的语义分割集合的 id 。由于减少了不同区域的错误影响，其优化效果得到一定的提升。但是存在奇异性。为了减少奇异性，一个思路是在更大的窗口中搜索和 i 点最接近的点，纳入计算。具体见公式(2)使用替代式(1)。

$$W'''(i, j) = \begin{cases} \frac{w(i, j)}{\sum_{j \in \mathbb{C}(i, 2r)} w(i, j)} & , j \in \mathbb{C}(i, 2r), i \in \Omega \\ 0 & , \text{others} \end{cases} \quad (2)$$

其中

$$\mathbb{C}(i, 2r) = \{j | j \in N(i, 2r), j \neq i, w(i, j) \leq w_{\text{sort}}(i, 2r)[r^2]\}$$

, $w_{\text{sort}}(i, 2r)$ 为对 $w = \{w(i, j) | j \in N(i, 2r), i \neq j\}$ 进行升序排序之后的数组。效果如图3所示。可以看到(2)提到的策略，虽然没有用到分割信息，但是仍然取得了不错的效果。



图 1: 使用全局约束但是没有利用语义分割 图 2: 使用全局约束利用语义分割 图 3: 利用更大窗口中的最近似策略

1.2 tgv收敛问题

在^[4]中的算法1，可以看成是Chambolle^[3]提到

的Algorithm2和Pock^[7]提到的算法的结合版本。通过引入一个类似学习因子的变量，不断在迭代中缩短优化的步长值。虽然对于初始点比较靠近收敛点的算法，能够起到加快收敛的效果。但是对于我们的使用场景中而言，由于初始点和收敛点距离较远，所以反而会减慢收敛速度。对此采取的改进是，将 τ, σ, θ 设置成定值。见算法2 改善之后的

Algorithm 1 pdTGVL2

Initialization: Choose $\tau_0, \sigma_0 > 0$, with $\tau_0 \sigma_0 L^2 \leq 1, (x^0, y^0) \in X \times Y$ and set $\bar{x}^0 = x^0$.

Caculate Tensors: Choose $\alpha \in [0, 2]$ and Caculate as follow :

$$\begin{aligned} T &= \text{diag}(\boldsymbol{\tau}), \text{ where } \boldsymbol{\tau} = (\tau_1, \dots, \tau_n), \tau_j = \frac{1}{\sum_{i=1}^m |K_{i,j}|^{2-\alpha}}, \\ \Sigma &= \text{diag}(\boldsymbol{\sigma}), \text{ where } \boldsymbol{\sigma} = (\sigma_1, \dots, \sigma_m), \sigma_i = \frac{1}{\sum_{j=1}^n |K_{i,j}|^\alpha} \end{aligned} \quad (3)$$

Iterations($k \geq 0$): Update x^n, y^n, \bar{x}^n as follows :

$$\begin{aligned} x^{k+1} &= (I + \tau_k T \partial G)^{-1} (x^k - \tau_k T K^T y^k), \\ y^{k+1} &= (I + \sigma_k \Sigma \partial F^*) (y^k + \sigma_k \Sigma K \bar{x}^k). \\ \theta_k &= \frac{1}{\sqrt{1 + 2\gamma\tau_k}}, \tau_{k+1} = \theta_k \tau_k, \sigma_{k+1} = \frac{\sigma_k}{\tau_n} \\ \bar{x}^{k+1} &= x^{k+1} + \theta_k (x^{k+1} - x^k) \end{aligned} \quad (4)$$

算法效果如图5 所示，可以看到算法收敛速度得到明显改善。算法参数为 $\text{iterTimes} = 10000, \alpha_w = 17, \alpha_u = 5, \lambda = 1e-2, \tau = 1, \sigma = 1, \theta = 1$ 耗时700s(stgv)和1000s(cstgv) ,ITGV迭代5000次,使用的参数为 $\text{iterTimes} = 5000, \alpha_w = 5, \alpha_u = 1.2, \lambda = 1e-2, \tau = 1, \sigma = 1, \theta = 1$, 耗时为346.905s 实验中发现，TGV算法对正则项f的分布依赖性比较大，当f中存在异常值时，会导致修复效果错误。可以看到，当初始值中移除了错误深度数据之后。算法效果得到明显的改善，使用的参数为 $\text{iterTimes} = 5000, \alpha_w = 5, \alpha_u = 1.2, \lambda = 1e-2, \tau = 1, \sigma = 1, \theta = 1$

使用循环边界测试了一下tgv的收敛效果。发现循环边界会引入异常，见图6,分析可能的原因是，因为用了循环边界差分，在第m行的 ∇_y 的计算中引入了第0行的数据，也就是第0行的深度值会影响最后一行的深度补偿效果。



(a) STGV效果,收敛慢,迭代14730次



(b) STGV效果,收敛快,迭代10000次,耗时700s



(c) CSTGV效果,收敛快,迭代10000次,耗时1000s



(d) ITGV效果,收敛快,迭代5000次,耗时346.9s

图 4: 收敛速度提升后的优化效果

Algorithm 2 pdTGV L2_fixStep

Initialization: Choose $\tau_0, \sigma_0 > 1/\tau_0$, $\theta = 1, (x^0, y^0) \in X \times Y$ and set $\bar{x}^0 = x^0$.

Caculate Tensors: Choose $\alpha \in [0, 2]$ and Caculate as follow :

$$\begin{aligned} T &= \text{diag}(\boldsymbol{\tau}), \text{ where } \boldsymbol{\tau} = (\tau_1, \dots, \tau_n), \tau_j = \frac{1}{\sum_{i=1}^m |K_{i,j}|^{2-\alpha}}, \\ \Sigma &= \text{diag}(\boldsymbol{\sigma}), \text{ where } \boldsymbol{\sigma} = (\sigma_1, \dots, \sigma_m), \sigma_i = \frac{1}{\sum_{j=1}^n |K_{i,j}|^\alpha} \end{aligned} \quad (5)$$

Iterations ($k \geq 0$): Update x^n, y^n, \bar{x}^n as follows :

$$\begin{aligned} x^{k+1} &= (I + \tau_0 T \partial G)^{-1} (x^k - \tau_0 T K^T y^k), \\ y^{k+1} &= (I + \sigma_0 \Sigma \partial F^*) (y^k + \sigma_0 \Sigma K \bar{x}^k). \\ \bar{x}^{k+1} &= x^{k+1} + \theta (x^{k+1} - x^k) \end{aligned} \quad (6)$$



(a) 含有错误值的初始图像



(b) 移除了错误值的初始图像



(c) 用正确初始图像的修复效果, STGV, 耗时389.9s



(d) 用正确初始图像的修复效果, CSTGV, 耗时577s

图 5: 初始值对TGV效果影响




图 6: 循环边界导致数据异常


2 单目深度测算

2.1 色差dfd



利用透镜的对不同颜色的对焦参数（焦距）不同，可以利用单张图片进行深度信息解算^{[2][5]}。色差信息的使用带来的好处是只用一张图片就可以解决传统dfd深度解算的二义性，也即只通过一张图片，仅能估计出模糊半径，但是模糊半径可能是对焦像平面在传感器靶面之前或者之后的两种可能位置造成的。也就是可能的深度解有两个。而色差信息，由于不同波长的光的焦距不一样，其成像的模糊半径也不一样，一张图片可以获取多种光谱的不同的模糊半径，因此能够消除深度解算的二义性。受其启发，是否可以利用像散进行DFD计算。也即将液晶透镜水平和垂直的光焦度设置成不同的值，形成椭圆形透镜，由于像散的图像在不同的深度范围具有不同的长轴和短轴，因此可以消除二义性。利用Levin^[6]提出的KL散度模型



(a) 模糊形成示意




(b) 单张DFD解算二义性



(c) 多光谱DFD示意

图 7: 色差DFD^[2]

图 8: 像散示意图^[1]

来测算椭圆形的模糊光斑在相近距离的区分度。

$$D_{KL}(P_{k1}, P_{k2}) = \sum v, w \left(\frac{\sigma_{k1}(v, w)}{\sigma_{k2}(v, w)} - \log \left(\frac{\sigma_{k1}(v, w)}{\sigma_{k2}(v, w)} \right) \right) \quad (7)$$

$$\sigma(v, w) = |F_k(v, w)|^2 (\alpha |G_x(v, w)|^2 + \alpha |G_y(v, w)|^2)^{-1} + \eta^2$$

其中 $F_k(v, w)$ 为PSF的傅里叶变换, $G_x(v, w), G_y(v, w)$ 为水平和垂直差分算子的傅里叶变换。 η 为噪声的方差。椭圆透镜的KL散度见图9

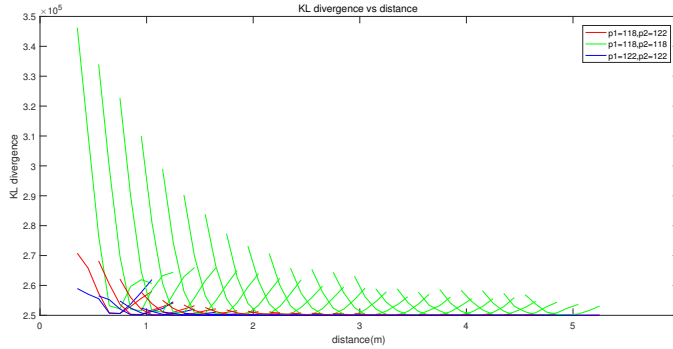


图 9: 椭圆透镜的KL散度

3 接下来的工作

- 结合文献^[8]和文献^[9], 编写dfd算法, 考虑结合使用多尺度信息和其他

的结构信息;

- 进一步实验验证单张图进行DFD的可能性

参考文献

- [1] 叶玉堂. 光学教程 (第二版) .
- [2] Benjamin Buat, Pauline Trouvé-Peloux, Frédéric Champagnat, Guy Le Besnerais, and Thierry Simon. Active chromatic depth from defocus for industrial inspection. In *Unconventional Optical Imaging II*, volume 11351, page 113510Z. International Society for Optics and Photonics, 2020.
- [3] Antonin Chambolle and Thomas Pock. A first-order primal-dual algorithm for convex problems with applications to imaging. *Journal of Mathematical Imaging and Vision*, 40(1):120–145, May 2011.
- [4] David Ferstl, Christian Reinbacher, Rene Ranftl, Matthias Ruether, and Horst Bischof. Image guided depth upsampling using anisotropic total generalized variation. In *2013 IEEE International Conference on Computer Vision*, pages 993–1000, 2013.
- [5] Shin Ishihara, Antonin Sulc, and Imari Sato. Depth estimation using spectrally varying defocus blur. 2021.
- [6] Anat Levin, Rob Fergus, Frédo Durand, and William T Freeman. Image and depth from a conventional camera with a coded aperture. *ACM transactions on graphics (TOG)*, 26(3):70-es, 2007.
- [7] Thomas Pock and Antonin Chambolle. Diagonal preconditioning for first order primal-dual algorithms in convex optimization. In *2011 International Conference on Computer Vision*, pages 1762–1769, 2011.
- [8] Ambasamudram N Rajagopalan and Subhasis Chaudhuri. An mrf model-based approach to simultaneous recovery of depth and restoration from defocused images. *IEEE transactions on pattern analysis and machine intelligence*, 21(7):577–589, 1999.

- [9] Ashutosh Saxena, Sung H Chung, Andrew Y Ng, et al. Learning depth from single monocular images. In *NIPS*, volume 18, pages 1–8, 2005.